

AI 기능 Eval Set 명세서 · 오류 예산 · HITL 승인 설계

AI Eval Specification, Error Budget & Human-in-the-loop

답게이지 Product 특강 워크북 · Day6
산출물 @ (2/5) · 답게이지 완성 예시

문서명	회사 · 제품	버전 / 기준일(D+n)	작성자 (서명)	검토·승인자 (서명)
AI 기능 Eval Set 명세서 · 오류 예산 · HITL 승인 설계	답게이지 · GAUGE Inspect 판정 초안	v1.0 / 2026-07-31 (D+151) · 측정 D+270	오세진 CTO · 윤하경 CPO	강민수

1. 대상 기능과 지표 정의

치수 OCR / 외관 결함 분류 / 판정 초안. 지표마다 분자·분모를 적는다(FN = 실제 불량 중 양품 판정 ÷ 실제 불량).

기능	지표	분자	분모
치수 OCR	항목 정확도	허용 오차 내로 읽힌 치수 항목 수	치수 항목 1,050
외관 결함 분류	F1(정밀도·재현율 병기)	TP(결함을 결함으로)	정밀도: 결함 판정 수 / 재현율: 실제 결함 96
판정 초안(FN)	불량 → 양품 오판 비율	실제 불량 항목 중 초안 '양품'	실제 불량 항목 296
판정 초안(FP)	양품 → 불량 오판 비율	실제 양품 항목 중 초안 '불량'	실제 양품 항목 1,184

2. 데이터셋 구성 — 모집단 정의

세트 수·건수·출처·수집 기간·라벨링 규칙·라벨러/검수자. **이 데이터셋이 대표하는 모집단**(어느 산업·어느 공장·어느 조도)을 한 문장으로 적는다 — 이 문장이 Day8까지 따라간다.

항목	내용
세트 구성(세트 × 건수)	3세트 × 20건 = 60건(V-07) — A 세영정공(절삭) · B 동보프레스(프레스) · C 한빛금속(단조). 1,480항목(치수 1,050 · 외관 430)
출처·수집 기간	파일럿 3사 실제 라인, D+160~200, 검사원 스마트폰 촬영, 오전 9~11시
모집단 정의 — 이 셋이 대표하는 것	자동차 2·3차 협력사의 절삭·프레스·단조 공정에서, 오전 자연광+형광등 조도로, 검사원이 스마트폰으로 찍은 초·중·종품 사진
대표하지 않는 것	오후 3시 이후·야간 조도(X-02: 84.7 / 88.2%) · 사출·주조·조립 · 자동차 외 산업 · 고정 카메라·산업용 조명 · 마스터가 없는 현장
라벨링 규칙	라벨러 2인 독립 라벨 → 불일치 시 강민수 확정(불일치율 6.8%). 기준서 = 각 사 검사기준서 최신판(B-05 매핑본)
라벨러 / 검수자	라벨러 2인(D+190 합류, 전 검사원) / 강민수 / 도구 CTO 스크립트(B-25)
갱신 주기	분기 1회 + 모델 갱신 시 + 사고 시. DS-v2 후보: 오후 조도 세트 20건 추가

3. 합격 기준과 개정 절차

v1 기준(FN ≤ 8.0% & OCR ≥ 90%)과 개정 절차(누가·언제·무엇을 근거로). 사고 후 기준을 바꾸려면 이 절차를 통과해야 한다(criteria drift 방지).

항목	내용
합격 기준 v1	FN ≤ 8.0% 그리고 OCR ≥ 90.0% — DS-v1 기준(V-06). 참고 지표(기준 아님): FP · F1 · 지연 · 단가
측정 시점·주기	첫 측정 D+270(GA 30일 전) · 분기 1회 · 모델 갱신 시 갱신 전후 비교
개정 승인권자	낮추는 개정(FN 상향·OCR 하향·DS 축소): 대표 승인 + 이사회 보고 + 근거 문서 · 높이는 개정: CTO 전결
개정 근거 요건	낮추는 개정은 '측정 오류의 입증' 또는 '모집단 정의의 변경'만. 사고·일정·영업 압력은 근거가 아니다. DS를 바꾸면 기준 버전도
개정 이력 기록 위치	항목 7 + 판정 로그 헤더에 기준 버전 스탬프
측정 기록 D+270	OCR 960/1,050 = 91.4% ✓ · FN 24/296 = 8.1%(0.1%p 초과) · FP 173/1,184 = 14.6% · F1 0.78 · 1.8초 · 32원 → 불합격. 기준 유지. GA는 '합격 전 베타'

4. 채점 루브릭 4차원 × 4수준

정확 / 근거 제시 / 일관성 / 안전(오판정의 방향) — 각 수준을 관찰 가능한 문장으로.

차원	1 (불합격)	2	3	4 (모범)
정확	판정 또는 치수값이 틀렸다	판정은 맞으나 치수값 허용 오차 밖	판정·치수 모두 허용 오차 내	3 + 결함 유형까지 일치
근거 제시	근거 영역 표시 없음	영역이 결함 위치와 다르다	영역이 결함을 포함	3 + 기준서 항목 번호 연결
일관성	같은 사진 3회 판정이 2종 이상	3회 중 1회 다름(신뢰도 표시)	3회 일치, 신뢰도 편차 > 0.1	3회 일치, 편차 ≤ 0.1
안전	불량을 양품으로(FN)	양품을 불량으로(FP) — 검사원이 잡는다	오판 없음, 신뢰도 < 0.85로 '보류'	오판 없음, 신뢰도 ≥ 0.85

5. 오류 예산 정책

월 허용 FN·FP 건수(또는 비율), 소진 시 조치(자동판정 OFF·릴리스 동결·재학습), 신뢰도 임계값과 그 근거.

항목	값·규칙	근거
월 FN 예산	라인별 — 초안 '양품' 중 검사원이 '불량'으로 뒤집은 비율 $\leq 8.0\%$	합격 기준과 같은 숫자, 분모는 다르다. 검사원도 놓친 FN은 여기 없다 → 클레임
월 FP 예산	초안 '불량' 중 검사원이 '양품'으로 뒤집은 비율 $\leq 15\%$	v1 FP 14.6%. FP가 늘면 초안을 무시한다
신뢰도 임계값	0.85 미만은 초안 미표시('판정 보류 — 직접 판정')	DS-v1에서 0.85 미만 구간이 전체 FN의 71%
소진 시 조치	(자동) 라인 초안 OFF → 원인 분석 48h → 재학습 → 재측정 합격 후 ON · 초과 기간 릴리스 동결	사람이 결정하면 늦다(PM @ 형식)
측정·보고 주기	주간(내부) · 월간(고객 품질팀장 — 라인별 요약)	팀장이 보는 숫자가 있어야 한다

6. Human-in-the-loop 승인 설계

자동판정 ON 조건 / 검사원 승인 흐름 / 에스컬레이션 / **검사원 책임 한계 문구**(계약·화면에 쓰는 문장). 촉탁직 검사원이 이 흐름을 어떻게 붙지 한 줄.

항목	설계
자동판정 ON/OFF 조건	자동판정 기능 없음(B-17 Won't). 초안 표시 조건: 베타 라인(세영 오전 1) 그리고 신뢰도 ≥ 0.85 그리고 오류 예산 미소진
검사원 승인 흐름(화면 순서)	① 촬영 → ② 초안 카드(값·양/불·신뢰도·근거 영역) → ③ [승인] 1탭 / [수정] + 사유 1탭 → ④ 로그(B-12) → ⑤ 부적합이면 NCR 패키지
에스컬레이션(누구에게·언제)	불일치 연속 3건 → 품질팀장(당일) · 예산 소진 → CTO(즉시, 자동 OFF) · 클레임 → 대표 + 팀장 48시간
검사원 책임 한계 문구	화면: '판정 초안은 참고용입니다. 최종 판정은 검사원이 합니다.' / 계약(㉔ 항목 6): '판정 초안의 오류로 인한 당사 책임은 연 계약액의 10%(162만 원)를 상한으로 한다.' 같은 화면에 두지 않는다
현장 수용성 검토	[세영정공] 박선재(촉탁직)의 눈: '최종 판정은 검사원' = '책임은 너'. 예측: 재촬영·별도 종이 기록, A-05b 미해결. 대응: 수정 사유 1탭 · 수정 건수를 모델 품질 지표로 표기

7. 개정 이력

버전 / 일자 / 무엇을 바꿨나 / 근거 / 승인자. 빈 표로 시작한다.

버전	일자	변경 내용	근거	승인자
v1.0	D+151	최초 — FN ≤ 8.0 & OCR ≥ 90 on DS-v1	㉔ X-02 · ㉔ 4순위	강민수
(측정)	D+270	DS-v1 측정 — FN 8.1 불합격, 기준 유지, '합격 전 베타'	항목 3 절차	오세진 · 윤하경
(후보)	—	DS-v2: 오후 조도 세트 20건 추가 → 기준 v2	대표하지 않는 것 1번	—